

FlashKDA 迁移到 SM100 是否值得?

B300 上的复现、因果分析与双分支探索

01

复现与测量

02

分析

03

挑战

奶龙必胜

HMMA 兼容路径与 tcgen05 原生路径

C1 研究主线

研究问题 在同一套 FlashKDA 接口与数值约束下，SM100 原生路径能否产生足以覆盖迁移成本的实际收益？

- | | | | |
|-------|--------------|------------------------|------------------|
| 01 | 复现与测量 | 锁定执行身份、正确性与公开接口计时边界 | 指令身份、利用率与计时 |
| <hr/> | | | |
| 02 | 分析 | 用双分支闭环生成可比证据，再把六问收敛为规律 | 双分支 agent 与双层 IR |
| <hr/> | | | |
| 03 | 挑战 | 沿四条路径推进候选，并用数据与知识完成晋级 | 替换、布局与全栈 |
| <hr/> | | | |

回答 在已测 B300 工作负载上，SM100 值得以受条件保护的后端方式加入；有效迁移单位是全栈协同，而不是单独替换矩阵乘加指令。

KDA 递推结构

一个 chunk



CHUNK = 16

数值范围、16×16 求解与 SM80 MMA 形状共同形成的设计点。

递推正确性

一次调用要同时验证 output 与 final state；连续调用还要检查 state handoff。

可利用并行

chunk 内 K2 串行，但 head、value slice、sequence 与角色仍可并行。

官方路径仍使用 HMMA

执行身份

FlashKDA

版本已固定

CUTLASS

版本已固定

目标架构

sm_103a

反汇编

实际加载 .so

同一复现同时记录

- 01 实际加载模块路径
- 02 源码与二进制 SHA-256
- 03 Python 导入来源
- 04 CUDA 头文件版本
- 05 实际执行路径

3,640

条 HMMA 矩阵乘加指令

0

SM100 原生 tcgen05、UTCMMA

源码命名不是证据；实际加载二进制的指令身份才是。

计时与正确性边界

计时边界



- 01 **状态一致** 每次调用使用相同非零初态，重复测量时轮转状态槽位。
- 02 **进程隔离** 每个实现使用独立进程，避免 CUDA 符号覆盖改变实际执行路径。
- 03 **双重正确性** 同时检查输出与最终状态，并覆盖打包、尾块和连续两次调用。
- 04 **正式性能** 冷 L2、CUDA 性能接口（CUPTI）、平衡顺序与 ABBA 交替复测。

双分支公平比较

只把优化后的新路径与未优化旧路径比较，会把架构收益和搜索努力混在一起。

HMMA 兼容分支



tcgen05 原生分支



共享实验合同

同一工作负载

q / k / v / 状态 / 打包边界

同一机会预算

每轮候选与搜索机会匹配

同一证据门槛

实际路径、正确性与完整接口计时

公平问题 比较的是同预算最优边界，而不是新旧指令的静态标签。

MARPE 探索闭环

MARPE：多智能体运行时画像演化（Multi-Agent Runtime Profile Evolution）

01

开放提案

代码补丁、结构扩展
与机制探针

02

候选分配

HMMA 兼容分支与
tcgen05 原生分支

03

隔离执行

独立 GPU、性能分析
与实验快照

04

证据晋级

实际路径、正确性
与 ABBA 复测

05

双层写回

程序 IR 与经验 IR

写回的两类产物

数据

时延样本、正确性、二进制指令、路径凭据与硬件计数器

知识

机制解释 · 失败边界 · 适用范围 · 允许复用方式 · 下一轮高价值提案

双层 IR

程序中间表示 (Program IR)

回答：实际执行了什么

- 01 算子约束与实际路径
- 02 源码、头文件、动态库与哈希
- 03 硬件架构、编译器与路由条件
- 04 调度、布局与同步
- 05 Python 解释器、导入来源与搜索路径

经验中间表示 (Experience IR)

回答：这条证据能在哪里复用

- 01 候选提案、结果与不确定性
- 02 机制状态与失败原因
- 03 执行路径、架构与注意力头数
- 04 工作负载、阶段与计时范围
- 05 允许复用范围与必须重测条件

例 1 V16 核心探针 1.615× 只说明首选布局有潜力，不能直接写成公开路径赢家。

例 2 HMMA nseq3 的 1.076× 不外推到 nseq4；后者实测为 0.962×。

三个关键结论

Q1 · Q5

数值约束决定分块设计

CHUNK16 同时约束指数恢复、16×16 求解和 BF16 状态舍入；扩大到 C32/C64 需要重新缩放或分块求解。

输出、最终状态、连续两次调用

Q2 · Q4

分块合法不等于整体高效

tcgen05 还要承担张量内存（TMEM）、地址描述符、同步和读回；H12 受低并行度与关键路径限制。

V128 0.920× 计算 / 显存
2.64%/1.24%

Q3 · Q6

并行机会决定迁移和部署方式

注意力头、数值维、序列和生产 / 消费角色仍可并行；收益经工作负载认证后进入条件后端。

H12 value 切片时延 – 27.0%

四条挑战路径




每条路径都经过同一五步

- 问题定义
- 候选实现
- 正确性门槛
- 计时范围
- 下一轮知识写回

tcgen05 的承载成本

每一行使用自己的基线和计时范围



知识 tcgen05 核心计算有潜力，但布局、张量内存与同步协议决定公开路径是否胜出。

CAKE 全栈路径

公开接口完整加速比 = 官方时延 / 候选时延

图示代表工作负载； H3 为局部重排， CAKE 为全栈协同

H3 · H12

公开接口完整计时



H3 · H96

公开接口完整计时



CAKE · H12

完整计时 · T2



CAKE · H96

完整计时 · T2



1.0

知识 代数重排不足以缩短完整路径；驻留、角色、同步屏障、流水、布局与分发的协同才形成稳定收益。

八轮探索结果

HMMA 兼容分支		tcgen05 原生分支	
nseq3 V32/V64	1.076×	H96 s173 相对 CAKE	1.033×
skew3 V32/V64	1.077×	负载极小化调度	0.938×
nseq4 V32/V64	0.962×	首选布局 / 标量重构	1.227×
		首选布局 / HMMA	0.955×

写入经验 IR 的三条知识

- 01

HMMA 仍可优化

nseq3 仍有 7.6% 的可资格收益。
- 02

工作负载决定胜负

同一 V32/V64 在 nseq3 和 nseq4 方向相反。
- 03


局部收益须过门槛

首选布局优于标量重构，但相对匹配 HMMA 仍为 0.955×。

部署策略



- 路由规则** B300 的已认证工作负载进入 SM100 T2 。
- 兼容策略** 其他条件回退 HMMA , 保持跨代可用。
- 晋级证据** 实际执行路径、输出与状态正确性、公开接口完整计时。



图中方法的中文释义

双分支搜索

HMMA 与 `tcgen05` 独立优化

证据式晋级

实际路径、正确性、成本同时携带

双层中间表示

把运行数据转成带适用范围的经验

部署策略

已认证 SM100 路径，未覆盖 `profile` 回退 HMMA

最终回答 SM100 值得以受条件保护的后端方式加入 FlashKDA。