

FlashKDA 迁移到 SM100 是否值得？


B300 上的复现、因果分析与双分支探索

01 复现与测量

02 分析与知识写回

03 挑战与条件部署

奶龙必胜



HMMA 兼容路径与 tcgen05 原生路径

C1 研究主线

研究问题 在同一套 FlashKDA 接口与数值约束下，SM100 原生路径能否产生足以覆盖迁移成本的实际收益？

- | | | | |
|-------|--------------|------------------------|------------------|
| 01 | 复现与测量 | 锁定执行身份、正确性与公开接口计时边界 | 指令身份、利用率与计时 |
| <hr/> | | | |
| 02 | 分析 | 用双分支闭环生成可比证据，再把六问收敛为规律 | 双分支 agent 与双层 IR |
| <hr/> | | | |
| 03 | 挑战 | 沿四条路径推进候选，并用数据与知识完成晋级 | 替换、布局与全栈 |
| <hr/> | | | |

回答 在已测 B300 工作负载上，SM100 值得以受条件保护的后端方式加入；有效迁移单位是全栈协同，而不是单独替换矩阵乘加指令。

KDA 递推结构

一个 chunk



CHUNK = 16

数值范围、 16×16 求解与 SM80 MMA 形状共同形成的设计点。

递推正确性

一次调用要同时验证 output 与 final state；连续调用还要检查 state handoff。

可利用并行

chunk 内 K2 串行，但 head、value slice、sequence 与角色仍可并行。

官方路径仍使用 HMMA

执行身份

FlashKDA

版本已固定

CUTLASS

版本已固定

目标架构

sm_103a

反汇编

实际加载 .so

同一复现同时记录

- 01 实际加载模块路径
- 02 源码与二进制 SHA-256
- 03 Python 导入来源
- 04 CUDA 头文件版本
- 05 实际执行路径

3,640

条 HMMA 矩阵乘加指令

0

SM100 原生 tcgen05、UTCMMMA

源码命名不是证据；实际加载二进制的指令身份才是。

计时与正确性边界

计时边界




- 01 状态一致** 每次调用使用相同非零初态，重复测量时轮转状态槽位。
- 02 进程隔离** 每个实现使用独立进程，避免 CUDA 符号覆盖改变实际执行路径。
- 03 双重正确性** 同时检查输出与最终状态，并覆盖打包、尾块和连续两次调用。
- 04 正式性能** 冷 L2、CUDA 性能接口（CUPTI）、平衡顺序与 ABBA 交替复测。

双分支的公平性

架构收益只能从“同预算的最优边界”中被分离出来。

两条支路的搜索能量可以不同，但机会预算与证据门槛必须一致。



共享证据合同

- **工作负载** $q/k/v$ 、状态和打包边界一致
- **机会预算** 每轮候选数和搜索机会匹配
- **证据门槛** 身份、output + final state、public-full

比较对象 同预算的最优边界，不是新旧指令的标签。

双分支 Agent 的探索地形

快不是唯一产物：试探、证伪与适用边界一起改变下一轮搜索空间




KNOWLEDGE SEDIMENT 知识沉积

保留：负边界、适用 profile、作用域、重开条件

改变下一轮：关闭重复方向，把能量转移到未证伪边界

Typed IR 把语义与物理协议摆在同一条流上

每个节点都携带 shape、dtype、layout、carrier 与 lifetime，不合法的组合不会进入 CUDA



MECHANISM DECISION

inner64 长驻留: 1.430–1.446× vs HMMA

inner1 固定成本占主导, 回退 HMMA

完整 public-call 仍需重新取证

三个关键结论

Q1 · Q5

数值约束决定分块设计

CHUNK16 同时约束指数恢复、 16×16 求解和 BF16 状态舍入；扩大到 C32/C64 需要重新缩放或分块求解。

输出、最终状态、连续两次调用

Q2 · Q4

分块合法不等于整体高效

tcgen05 还要承担张量内存（TMEM）、地址描述符、同步和读回；H12 受低并行度与关键路径限制。

V128 $0.920 \times$ 计算 / 显存
2.64%/1.24%

Q3 · Q6

并行机会决定迁移和部署方式

注意力头、数值维、序列和生产 / 消费角色仍可并行；收益经工作负载认证后进入条件后端。

H12 value 切片时延 – 27.0%

四条挑战路径的投入与回报


气泡大小表示改造能量，位置表示完整路径的实测回报。



轨迹展示的不是线性进步。 Direct 和 H3 留下负边界，V16 揭示 carrier 问题，CAKE 才将这些知识组成完整收益。

tcgen05 的承载成本

每一行使用自己的基线和计时范围



承载层成本

地址描述符

张量内存

提交 / 等待

结果读回

数据布局

知识 tcgen05 核心计算有潜力，但布局、张量内存与同步协议决定公开路径是否胜出。

CAKE 全栈路径： 9/9 获益

公开接口完整加速比 = 官方时延 / 候选时延

图示代表工作负载； H3 为局部重排， CAKE 为全栈协同

H3 • H12

公开接口完整计时



H3 • H96

公开接口完整计时



CAKE • H12

完整计时 • T2



CAKE • H96

完整计时 • T2




1.0

知识 代数重排不足以缩短完整路径；驻留、角色、同步屏障、流水、布局与分发的协同才形成稳定收益。

知识闭包是一块已探明的地形

我们关闭的是已声明 finite grammar 与已测 profile，新算法、新映射或完整 public-call 会重新打开边界



准确表述


当前局部语法与已测 profile 已闭包

完整 SM100 KDA 仍依赖 full-call 移植

新增搜索轴会使证书失效


证据驱动的条件部署

线上路由不应求一刀切。证据足够的 profile 走 SM100，其余保留 HMMA 回退。



论文方法图

论文图 1 方法框架摘录



图中方法的中文释义

双分支搜索

HMMA 与 tcgen05 独立优化

证据式晋级

实际路径、正确性、成本同时携带

双层中间表示

把运行数据转成带适用范围的经验

部署策略

已认证 SM100 路径，未覆盖 profile 回退 HMMA

最终回答 SM100 值得以受条件保护的后端方式加入 FlashKDA。