

# FlashKDA 迁移到 SM100 是否值得？

B300 上的复现、因果分析与双分支探索

---

01

复现与测量

02

分析

03

挑战

# C1 研究主线

---

**研究问题** 在同一套 FlashKDA 接口与数值约束下，SM100 原生路径能否产生足以覆盖迁移成本的实际收益？

- |       |              |                        |                  |
|-------|--------------|------------------------|------------------|
| 01    | <b>复现与测量</b> | 锁定执行身份、正确性与公开接口计时边界    | 指令身份、利用率与计时      |
| <hr/> |              |                        |                  |
| 02    | <b>分析</b>    | 用双分支闭环生成可比证据，再把六问收敛为规律 | 双分支 agent 与双层 IR |
| <hr/> |              |                        |                  |
| 03    | <b>挑战</b>    | 沿四条路径推进候选，并用数据与知识完成晋级  | 替换、布局与全栈         |
| <hr/> |              |                        |                  |

**回答** 在已测 B300 工作负载上，SM100 值得以受条件保护的后端方式加入；有效迁移单位是全栈协同，而不是单独替换矩阵乘加指令。

# KDA 递推结构

一个 chunk



## CHUNK = 16

数值范围、 $16 \times 16$  求解与 SM80 MMA 形状共同形成的设计点。

## 递推正确性

一次调用要同时验证 output 与 final state；连续调用还要检查 state handoff。

## 可利用并行

chunk 内 K2 串行，但 head、value slice、sequence 与角色仍可并行。

# 官方路径仍使用 HMMA

## 执行身份

FlashKDA

1ce47ea

CUTLASS

5c149f5

目标架构

sm\_103a

反汇编

实际加载 .so

## 同一复现同时记录

- 01 实际加载模块路径
- 02 源码与二进制 SHA-256
- 03 Python 导入来源
- 04 CUDA 头文件版本
- 05 实际执行路径

3,640

条 HMMA 矩阵乘加指令

0

SM100 原生 tcgen05、UTCMMMA

源码命名不是证据；实际加载二进制的指令身份才是。

# 计时与正确性边界

## 计时边界



- 01 状态一致 每次调用使用相同非零初态，重复测量时轮转状态槽位。
- 02 进程隔离 每个实现使用独立进程，避免 CUDA 符号覆盖改变实际执行路径。
- 03 双重正确性 同时检查输出与最终状态，并覆盖打包、尾块和连续两次调用。
- 04 正式性能 冷 L2、CUDA 性能接口（CUPTI）、平衡顺序与 ABBA 交替复测。

# 双分支公平比较

只把优化后的新路径与未优化旧路径比较，会把架构收益和搜索努力混在一起。

## HMMA 兼容分支



## tcgen05 原生分支



## 共享实验合同

### 同一工作负载

q / k / v / 状态 / 打包边界

### 同一机会预算

每轮候选与搜索机会匹配

### 同一证据门槛

实际路径、正确性与完整接口计时

**公平问题** 比较的是同预算最优边界，而不是新旧指令的静态标签。

双分支 Agent 的知识驱动探索闭环


每轮的产物不只是更快候选，还包括失败边界、适用条件和下一项值得验证的假设

互补角色只提交 TYPED PATCH



P3、BF16 ROUND 与 P4 的 Typed IR 流水

类型同时约束 shape、dtype、layout、carrier 和 lifetime，非法组合在生成 CUDA 之前终止





# 三个关键结论

---

Q1 · Q5

## 数值约束决定分块设计

CHUNK16 同时约束指数恢复、 $16 \times 16$  求解和 BF16 状态舍入；扩大到 C32/C64 需要重新缩放或分块求解。

输出、最终状态、连续两次调用

Q2 · Q4

## 分块合法不等于整体高效

tcgen05 还要承担张量内存（TMEM）、地址描述符、同步和读回；H12 受低并行度与关键路径限制。

V128  $0.920 \times$  计算 / 显存  
2.64%/1.24%

Q3 · Q6

## 并行机会决定迁移和部署方式

注意力头、数值维、序列和生产 / 消费角色仍可并行；收益经工作负载认证后进入条件后端。

H12 value 切片时延 – 27.0%

# 四条挑战路径




每条路径都经过同一五步

问题定义   候选实现   正确性门槛   计时范围   下一轮知识写回

# tcgen05 的承载成本

每一行使用自己的基线和计时范围



承载层成本

地址描述符

张量内存

提交 / 等待

结果读回

数据布局

**知识** tcgen05 核心计算有潜力，但布局、张量内存与同步协议决定公开路径是否胜出。

# CAKE 全栈路径： 9/9 获益

公开接口完整加速比 = 官方时延 / 候选时延

图示代表工作负载； H3 为局部重排， CAKE 为全栈协同

## H3 • H12

公开接口完整计时



## H3 • H96

公开接口完整计时



## CAKE • H12

完整计时 • T2



## CAKE • H96

完整计时 • T2




1.0

**知识** 代数重排不足以缩短完整路径；驻留、角色、同步屏障、流水、布局与分发的协同才形成稳定收益。

有限 Typed Grammar 的局部知识闭包

闭包要求每个声明候选都有终态证据：扩大 grammar、profile 或 public-call 后必须重新开域




# 部署策略



- 路由规则** B300 的已认证工作负载进入 SM100 T2。
- 兼容策略** 其他条件回退 HMMA，保持跨代可用。
- 晋级证据** 实际执行路径、输出与状态正确性、公开接口完整计时。

# 论文方法图

论文图 1 方法框架摘录



## 图中方法的中文释义

### 双分支搜索

HMMA 与 `tcgen05` 独立优化

### 证据式晋级

实际路径、正确性、成本同时携带

### 双层中间表示

把运行数据转成带适用范围的经验

### 部署策略

已认证 SM100 路径，未覆盖 profile 回退 HMMA

**最终回答** SM100 值得以受条件保护的后端方式加入 FlashKDA。

提问 奶龙必胜