



FlashKDA 迁移到 SM100 是否值得？

B300 上的复现、因果分析与双分支探索

奶龙必胜 | 蔡雨洋 • 李奥 • 赵骋

复现与测量 • 分析与知识写回 • 挑战与条件部署



C1 研究主线

研究问题 在同一套 FlashKDA 接口与数值约束下，SM100 原生路径能否产生足以覆盖迁移成本的实际收益？

- | | | | |
|-------|--------------|------------------------|------------------|
| 01 | 复现与测量 | 锁定执行身份、正确性与公开接口计时边界 | 指令身份、利用率与计时 |
| <hr/> | | | |
| 02 | 分析 | 用双分支闭环生成可比证据，再把六问收敛为规律 | 双分支 agent 与双层 IR |
| <hr/> | | | |
| 03 | 挑战 | 沿四条路径推进候选，并用数据与知识完成晋级 | 替换、布局与全栈 |
| <hr/> | | | |

回答 在已测 B300 工作负载上，SM100 值得以受条件保护的后端方式加入；有效迁移单位是全栈协同，而不是单独替换矩阵乘加指令。

KDA 递推结构

一个 chunk



CHUNK = 16

数值范围、 16×16 求解与 SM80 MMA 形状共同形成的设计点。

递推正确性

一次调用要同时验证 output 与 final state；连续调用还要检查 state handoff。

可利用并行

chunk 内 K2 串行，但 head、value slice、sequence 与角色仍可并行。



官方路径仍使用 HMMA

执行身份

FlashKDA

1ce47ea

CUTLASS

5c149f5

目标架构

sm_103a

反汇编

实际加载 .so

同一复现同时记录

- 01 实际加载模块路径
- 02 源码与二进制 SHA-256
- 03 Python 导入来源
- 04 CUDA 头文件版本
- 05 实际执行路径

3,640

条 HMMA 矩阵乘加指令

0

SM100 原生 tcgen05、UTCMMMA

源码命名不是证据；实际加载二进制的指令身份才是。



计时与正确性边界

计时边界




- 01 状态一致** 每次调用使用相同非零初态，重复测量时轮转状态槽位。
- 02 进程隔离** 每个实现使用独立进程，避免 CUDA 符号覆盖改变实际执行路径。
- 03 双重正确性** 同时检查输出与最终状态，并覆盖打包、尾块和连续两次调用。
- 04 正式性能** 冷 L2、CUDA 性能接口（CUPTI）、平衡顺序与 ABBA 交替复测。

双分支的公平性

架构收益只能从“同预算的最优边界”中被分离出来。

两条支路的搜索能量可以不同，但机会预算与证据门槛必须一致。



共享证据合同

01 工作负载

q / k / v、状态与打包边界一致

02 机会预算

候选数与搜索机会按轮匹配


03 证据门槛

身份、双重正确性与 public-full

比较对象 两条支路在同一合同下得到的最优边界。

双分支 Agent 的探索地形

快不是唯一产物：试探、证伪与适用边界一起改变下一轮搜索空间




KNOWLEDGE SEDIMENT 知识沉积

保留：负边界、适用 profile、作用域、重开条件


改变下一轮：关闭重复方向，把能量转移到未证伪边界

Typed IR 把语义与物理协议摆在同一条流上

每个节点都携带 shape、dtype、layout、carrier 与 lifetime，不合法的组合不会进入 CUDA



RESOURCE LIFETIME



MECHANISM DECISION

inner64 长驻留: 1.430–1.446x vs HMMA

inner1 固定成本占主导, 回退 HMMA

完整 public-call 仍需重新取证



三个关键结论

Q1 · Q5

数值约束决定分块设计

CHUNK16 同时约束指数恢复、 16×16 求解和 BF16 状态舍入；扩大到 C32/C64 需要重新缩放或分块求解。

输出、最终状态、连续两次调用

Q2 · Q4

分块合法不等于整体高效

tcgen05 还要承担张量内存（TMEM）、地址描述符、同步和读回；H12 受低并行度与关键路径限制。

V128 $0.920 \times$ 计算/显存
2.64%/1.24%

Q3 · Q6

并行机会决定迁移和部署方式


注意力头、数值维、序列和生产/消费角色仍可并行；收益经工作负载认证后进入条件后端。

H12 value 切片时延 -27.0%

四条挑战路径的投入与回报

核心探针与 public-full 分开标注, $1.0\times$ 表示各自基线。


实测加速比



轨迹展示的不是线性进步。Direct 和 H3 留下负边界, V16 揭示 carrier 问题, CAKE 才将这些知识组成完整收益。

tcgen05 的承载成本

每一行使用自己的基线和计时范围



承载层成本

地址描述符

张量内存

提交 / 等待

结果读回

数据布局

知识 tcgen05 核心计算有潜力，但布局、张量内存与同步协议决定公开路径是否胜出。



CAKE 全栈路径：9/9 获益

公开接口完整加速比 = 官方时延 / 候选时延

图示代表工作负载；H3 为局部重排，CAKE 为全栈协同

H3 • H12

公开接口完整计时



0.905x

H3 • H96

公开接口完整计时



0.758x

CAKE • H12

完整计时 • T2



2.482x

CAKE • H96

完整计时 • T2




2.253x

1.0

知识 代数重排不足以缩短完整路径；驻留、角色、同步屏障、流水、布局与分发的协同才形成稳定收益。

知识闭包是一块已探明的地形

我们关闭的是已声明 finite grammar 与已测 profile, 新算法、新映射或完整 public-call 会重新打开边界



准确表述


当前局部语法与已测 profile 已闭包

完整 SM100 KDA 仍依赖 full-call 移植

新增搜索轴会使证书失效

证据驱动的条件部署

每个请求依次通过执行身份、递推正确性和 public-full 证据，再决定后端。




路由原则 已认证 profile 才进入 SM100，未覆盖或证据不足时保留 HMMA。

论文方法图

奶龙必胜



论文图 1 方法框架摘录



图中方法的中文释义

双分支搜索

HMMA 与 tcgen05 独立优化

证据式晋级

实际路径、正确性、成本同时携带

双层中间表示

把运行数据转成带适用范围的经验

部署策略

已认证 SM100 路径，未覆盖 profile 回退 HMMA

最终回答 SM100 值得以受条件保护的后端方式加入 FlashKDA。